

Домашнее задание — ёмкость слоя линейного внимания


В этом задании мы измерим, сколько ассоциаций «ключ — значение» может хранить слой линейного внимания. У softmax-внимания KV-кэш растёт с длиной контекста. Вся память линейного слоя, в отличие от него, — матрица $S \in \mathbb{R}^{d_k \times d_v}$ фиксированного размера, поэтому число ассоциаций, которые она различает, ограничено. Требуется вывести это ограничение как функцию d_k и проверить его экспериментом.

- **Что сдаётся:** сначала часть 1 — вывод и гипотеза, затем отчёт на 3–4 страницы. Оценка ставится за отчёт.
- **Время:** 5–8 часов работы и вычисления без присмотра: около 40 минут на GPU, 3–4 часа на 16 потоках CPU, до 16 часов на 4 потоках. GPU не обязателен, но, как вы понимаете, желателен если не хотите застрять надолго.

1. Задача MQAR

Модель решает задачу многозапросного ассоциативного воспроизведения (multi-query associative recall, MQAR). Словарь фиксирован: 256 токенов-ключей, 256 токенов-значений и один паддинг-токен.

Последовательность состоит из контекста и запросов. Контекст — пары «токен-ключ, токен-значение», между которыми стоят паддинг-токены. Запросы — токены-ключи из этих пар. На позиции каждого запроса модель должна выдать токен-значение из его пары.



Состав последовательности задают четыре числа:

- M — число пар, о которых спрашивают; пара занимает два токена;
- D — число токенов-дистракторов: $D/2$ пар, о которых не спрашивают;
- P — число паддинг-токенов между парами;
- $Q = 8$ — число запросов, по одному токenu на запрос.

Длина последовательности равна $N = 2M + D + P + Q$. Каркас подбирает P так, что $N = 128$ при любом M , поэтому длина контекста не меняется вместе с M .

Точность — доля запросов, на которые модель выдала верное значение. Случайное угадывание даёт $1/256$, выдача любого значения из контекста — $1/(M + D/2)$, то есть 0.125 при $M = 8$.

Точка коллапса M^* — наибольшее M , при котором точность на отложенной выборке не ниже 0.50 . Используйте это определение, иначе M^* нельзя будет сравнить с результатами других отчётов.

M пробегает отрезок $[8, 32]$. Меньше $Q = 8$ оно быть не может: запросы — различные ключи из пар. Больше 32 оно быть не может: примерно при $M + D/2 > 4Q = 32$ задачу не выучивает даже softmax-внимание. Поэтому размерности головы в задании малы: $d_k \in \{8, 10, 12, 16\}$.

2. Каркас

Каркас — пакет `linattn.homework` из публичного репозитория [linear-attention-public](#). Он содержит всё, кроме кода аппроксимации, и править его не нужно.

- **Данные** (`data.py`) синтетические и генерируются заново для каждого запуска: 32 768 обучающих последовательностей и 2 048 отложенных из независимого потока случайных чисел. Обучающая выборка конечна, поэтому точность на обучающей и на отложенной выборках может различаться.
- **Модель** (`model.py`) состоит из эмбеддингов токенов и позиций и двух блоков, в каждом из которых слой внимания и MLP. Ширина модели 128, одна голова, $d_v = 64$. Слой внимания задаётся ветвью:
 - ▶ softmax — softmax-внимание, контроль;
 - ▶ linear — $S_t = S_{t-1} + k_t v_t^\top$;
 - ▶ delta — $S_t = (I - \beta_t k_t k_t^\top) S_{t-1} + \beta_t k_t v_t^\top$, где $\beta_t \in (0, 1)$ вычисляется по входу слоя.

Чтение в линейных ветвях — $o_t = S_t^\top q_t$. Векторы q и k нормированы на единичную длину, v — нет. После проекций q, k, v стоит каузальная свёртка по времени ширины 4, выход слоя проходит RMSNorm.

- **Обучение** (train.py): AdamW, 2000 шагов, батч 64. Гиперпараметры заморожены.
- **Поиск M^*** (sweep.py) сначала измеряет точность в четырёх равноотстоящих точках отрезка $[8, 32]$, затем уточняет M^* бисекцией с точностью до 4.
 - ▶ Точка **цензурирована**, если M^* лежит вне отрезка. censored: "below" — ветвь не проходит порог уже при $M = 8$, censored: "above" — проходит его и при $M = 32$.
 - ▶ Флаг non_monotone означает, что точность после падения снова выросла. Это сбой оптимизации, а не предел памяти.

3. Порядок работы

Каждый студент прогоняет одно правило обновления, linear или delta, с двумя собственными seed. Правило и seed выводятся из фамилии, записанной латиницей.

1. Установка, проверка gate и запуск перебора.
2. Пока идёт перебор — часть 1. Гипотеза записывается до просмотра результатов перебора и сдаётся вместе с выводом.
3. Эталонные результаты — сетка reduced для обоих правил с seed 0 и 1. Архив reference.zip появится в релизах [linear-attention-public](#). Он распаковывается в results/, эталон ложится в results/reference/grid_reduced.json.
4. Затем часть 2, одно расширение и отчёт.

```

pip install --upgrade \
  "linattn[plot] @ git+https://github.com/voorhs/linear-attention-public@v0.2.1"
python -m linattn.homework.cli assign --student ivanov # правило и seed
python -m linattn.homework.cli gate # контроль, 2 запуска
python -m linattn.homework.cli time-run --arm linear --n-pairs 16 --d-k 12 # секунд на запуск
python -m linattn.homework.cli budget --student ivanov --seconds-per-run 248 # подставить своё число
python -m linattn.homework.cli sweep --student ivanov # перебор
python -m linattn.homework.cli plot --grid student --out figures # рисунки

```

Вместо ivanov подставьте свою фамилию.

gate обучает softmax-внимание при $M = 8$ и $M = 32$. Проверка пройдена, если в обеих точках точность на отложенной выборке выше 0.95. У softmax-внимания нет предела памяти, поэтому провал контроля означает, что модель не выучивает саму задачу. sweep не запускается, пока gate не пройден.

Сетка студента — 42 обучающих запуска:

- ёмкость: своё правило, $d_k \in \{8, 10, 12, 16\}$, два seed, до пяти запусков на поиск M^* ;
- softmax-контроль: $d_k = 16$, $M \in \{8, 32\}$.

Время — $(42 + 2) \times$ секунд на запуск, с учётом gate:

- 248 с на 16 потоках CPU дают 3 часа;
- 1057 с на 4 потоках — 13 часов;
- 43 с на RTX 3060 Laptop — 32 минуты.

Каждый запуск кэшируется в results/runs/, повторный вызов sweep продолжает с места остановки. Итог записывается в results/grid_student.json.

В Colab команды запускаются из ячейки с префиксом !. При отключении сессии диск стирается вместе с кэшем. Поэтому каталоги результатов следует держать на Google Drive: флаги --out, --summary-dir и --gate-out у sweep и extend и флаг --out у gate.

4. Часть 1 — вывод

Требуется вывести:

$$\text{SNR} = \frac{d_k}{W-1}, \quad W = 2M + D + Q, \quad M^* = c d_k - \frac{D + Q - 1}{2}, \quad c = \frac{1}{2\theta},$$

где W — число записей в состоянии в момент чтения, а θ — порог SNR, ниже которого чтение ошибается. При $Q = 8$ свободный член равен $-(D + 7)/2$. Наклон c не зависит от D , а значит, и от длины последовательности. Свободный член от D зависит.

Оценивается точность вывода: каждая величина определена, каждое допущение названо там, где используется, каждый переход показан. В лекции часть шагов упрощена, здесь они нужны полностью.

1. **Разложение чтения.** Запишите $S_t^\top q$ после W записей при $q = k_i$ как сумму сигнала и вектора помехи n .
2. **Мощность помехи.** Мощность — матожидание квадрата нормы, $\mathbb{E}\|n\|^2$; SNR — отношение мощностей сигнала и помехи. Допущения:
 - ключи независимы и равномерно распределены на единичной сфере в $\mathbb{R}^{d_k}$;
 - значения не зависят от ключей, $\|v_j\| = 1$.
 Покажите, почему перекрёстные члены в $\|n\|^2$ в среднем равны нулю, и выведите $\mathbb{E}[(k_j^\top k_i)^2] = 1/d_k$.
3. **Число записей W .** Укажите, для какого из Q запросов оно считается, и объясните, почему паддинг в него не входит.
4. **Прямая теории.** Найдите наибольшее M , при котором выполняется $\text{SNR} \geq \theta$.
5. **Дельта-правило.** Покажите, что при $\beta_t = 1$ и $\|k_t\| = 1$ чтение $S_t^\top k_t$ возвращает ровно v_t . Предскажите, выше или ниже прямой ветви `linear` лежат точки M^* ветви `delta`.
6. **Допущения и модель.** Для каждого допущения из п. 2 скажите, выполняется ли оно в модели из §2.
7. **Гипотеза из двух частей:**
 - значение c ;
 - сдвиг M^* при добавлении D дистракторов и при добавлении P паддинг-токенов.

Для каждой части назовите измерение, которое её опровергло бы.

5. Часть 2 — эксперимент

plot строит два рисунка в `figures/`:

- `accuracy-vs-m.png` — точность в зависимости от M , отложенная выборка сплошной линией, обучающая пунктиром;
- `collapse-vs-dk.png` — M^* в зависимости от d_k для каждого seed, цензурированные точки показаны пустыми треугольниками на краю отрезка.

Самостоятельно пишется только код аппроксимации. Собственные данные — `results/grid_student.json`, эталон — `results/reference/grid_reduced.json`; в обоих список `capacity`. Каждая запись содержит `arm`, `d_k`, `seed`, `m_star`, `censored`, `non_monotone` и `evaluated`. В `evaluated` для каждого измеренного M лежат `n_pairs`, `eval_acc` и `train_acc`.

Аппроксимация должна удовлетворять условиям:

- прямая $M^* = c d_k + b$ строится методом наименьших квадратов со свободным членом — по собственным данным и по эталону для каждой ветви;
- c и b приводятся по каждому seed вместе с разбросом;
- цензурированные точки исключены из подгонки и перечислены в тексте;
- точки с `non_monotone` обсуждаются отдельно;
- одним предложением объяснено, почему подгонка через начало координат исказила бы c и как это выглядело бы на рисунке.

Рисунки нужно дополнить:

- на collapse-vs-dk.png — прямыми аппроксимации, прямой теории из части 1 и эталонными точками обеих ветвей;
- на accuracy-vs-m.png — точностью softmax-контроля (список softmax_control того же файла).

В тексте сравните c с предсказанием, а $b - c - (D + 7)/2$. Сравните собственные M^* с эталоном для того же правила и проверьте по эталону предсказание п. 5 части 1 о delta и linear. Затем прочитайте пары кривых. Предел памяти снижает обучающую и отложенную точность вместе: состоянию безразлично, встречалась ли последовательность при обучении. Если обучающая точность высокая, а отложенная низкая, модель запомнила обучающие последовательности весами, и такая точка не измеряет состояние.

6. Часть 3 — одно расширение

Выберите одно из четырёх расширений и запустите его командой extend:

```
python -m linattn.homework.cli extend --student ivanov --which a --dry-run # число запусков
python -m linattn.homework.cli extend --student ivanov --which a # запуски
```

Запуски, которые уже сделала сетка студента, берутся из кэша. Итог записывается в results/extension_<буква>.json, для (a) и (b) строится ещё рисунок figures/extension-<буква>.png.

- **(a) Отрицательные контроли** — 3 запуска. Своё правило, $d_k = 16$, $M = 16$, первый seed: размер чанка 16, 32 и 64 и длина $N = 64$ и 128 за счёт паддинга.
 - ▶ Чанковая форма при любом размере чанка вычисляет ту же функцию, что и рекуррентность. Поэтому отличия по размеру чанка возникают только из порядка суммирования в плавающей точке — оцените их сверху.
 - ▶ Отсутствие эффекта паддинга — предсказание: слой может научиться ничего не записывать для одного и того же инертного токена.

Сообщите оба результата и объясните, что означало бы, если бы не прошёл только один из контролей.

- **(b) Число записей** — 9 запусков, 14 при правиле delta. Всегда linear, потому что сдвиг выведен для него: $d_k = 16$, $D \in \{0, 16, 32\}$, первый seed. Проверьте, что M^* сдвигается на $-D/2$. Сдвиг 0 соответствовал бы утверждению «ёмкость не зависит от длины», сдвиг $-D$ — подсчёту записей по парам.
- **(c) Равные байты состояния** — 10 запусков. Сравните $(d_k, d_v) = (16, 32)$ и $(8, 64)$ на своём правиле: оба состояния содержат по 512 чисел. Байты растут как $d_k d_v$, а по прямой теории M^* зависит только от d_k .
- **(d) Гибрид** — 10 запусков. Второй слой — softmax-внимание, первый — своё правило, $d_k = 8$; сравнение — с той же точкой без гибрида из сетки студента. Сообщите M^* и оба числа состояния из §7 для каждого слоя.

7. Два числа состояния

Каждая архитектура модуля описывается двумя величинами: **байты состояния на слой при длине контекста N** и **прирост байтов на токен, на слой**. В fp32 (4 байта на число) при H головах:

ветвь	байты состояния на слой при длине контекста N	прирост байтов на токен, на слой
linear, delta	$4Hd_k d_v$, не зависит от N	0
softmax	$4H(d_k + d_v)N$	$4H(d_k + d_v)$, ненулевой

Для softmax-внимания $d_k + d_v$ — ключ и значение одного токена в KV-кэше; при $d_k = d_v = d$ получается $2d$ из лекции.

Приведите оба числа для собственной конфигурации при $N = 128$ и для softmax-контроля из сетки ($d_k = 16$, $d_v = 64$) при той же длине. Формулировка «байты состояния на токен» в отчёте запрещена.

Для softmax-внимания это прирост, а для линейного слоя — величина $4Hd_kd_v/N$, которая убывает с N и ничего не описывает.

8. Отчёт

Отчёт занимает 3–4 страницы. Разделы идут в таком порядке:

1. **Предсказание:** вывод части 1 и гипотеза.
2. **Дизайн:** что меняется, что фиксировано, как проверен контроль.
3. **Результат:** рисунки части 2, аппроксимация, сравнение с предсказанием.
4. **Расширение.**
5. **Два числа состояния.**
6. **Три формы** — два абзаца по лекции и семинару:
 - перенос состояния между чанками и почему внутричанковая маска включает диагональ;
 - почему рекуррентная форма, выполняющая меньше FLOP, чем параллельная, обучается медленнее; объяснение — через арифметическую интенсивность и число последовательных шагов.
7. **Что изменило бы вывод:** измерение, которое опровергло бы результат, и сделано ли оно.

У каждого рисунка есть подпись, формулирующая утверждение. При размещении в отчёте рисунки должны оставаться читаемыми. Оси, единицы и базовые легенды задаются командой `plot`; их оформление отдельно не оценивается. Числа в тексте совпадают с рисунками.

9. Оценивание

Оцениваются вывод, дизайн эксперимента и прочтение данных, а не согласие теории с экспериментом. Аккуратно выведенная гипотеза, которую эксперимент опровергает, изложенная вместе с данными и с указанием нарушенного допущения, получает полный балл.

критерий	баллы
Вывод части 1	20
Гипотеза и условия её опровержения	10
Дизайн эксперимента	15
Аппроксимация	15
Расширение	10
Два числа состояния	10
Три формы	10
Оформление отчёта	10

Максимум — **100 баллов**. Ниже указано, из каких пунктов складывается балл за каждый критерий. Полный балл за пункт ставится, если выполнены все перечисленные в нём требования. При частичном выполнении начисляется часть баллов: например, верный ответ без требуемого обоснования или результат без данных для его проверки не получает полный балл. Отсутствующий пункт или принципиально неверное решение оценивается в 0 баллов за этот пункт.

Ошибки учитываются внутри соответствующих пунктов, без дополнительного штрафа сверх их стоимости. Если одна ошибка в выводе переносится в дальнейшие расчёты, за неё баллы снимаются один раз; последующие переходы оцениваются относительно явно записанной студентом формулы. Самостоятельные ошибки в этих переходах оцениваются отдельно.

9.1. Вывод части 1 — 20 баллов

- **3 балла — сигнал и помеха.** Чтение после W записей разложено на слагаемое с нужным значением и сумму остальных слагаемых. Определены индекс нужной записи, запрос $q = k_i$ и вектор помехи n ; понятно, какие записи входят в сумму.
- **4 балла — скалярные произведения ключей.** Из независимости и равномерного распределения ключей на единичной сфере выведено $\mathbb{E}[(k_j^\top k_i)^2] = 1/d_k$ для $j \neq i$. Объяснено, где используется симметрия распределения; одной ссылки на готовую формулу недостаточно.

- **4 балла — мощность помехи и SNR.** Квадрат нормы n раскрыт в сумму диагональных и перекрёстных членов. Обосновано, почему матожидания перекрёстных членов равны нулю, указана роль допущений о значениях. Получены мощность помехи и $\text{SNR} = d_k/(W - 1)$; мощности не подмечены нормами или амплитудами.
- **3 балла — число записей.** Получено $W = 2M + D + Q$ с подсчётом по токенам. Указано, на каком запросе считается W , учтены записи запросов и объяснено исключение паддинга. Просто подставленная без объяснения формула не даёт полный балл.
- **2 балла — прямая теории.** Из неравенства $\text{SNR} \geq \theta$ получена граница по M , определены c и свободный член, подставлено $Q = 8$. Показано, почему D меняет свободный член, а не наклон.
- **2 балла — дельта-правило.** Подстановкой в правило обновления доказано $S_t^\top k_t = v_t$ при $\beta_t = 1$ и единичной норме ключа. Сформулировано и обосновано предсказание о взаимном положении точек delta и прямой linear.
- **2 балла — границы применимости.** Каждое допущение о ключах и значениях из §4 сопоставлено с моделью из §2. Различены свойства, обеспеченные архитектурой, и предположения, которые для обученных представлений могут не выполняться.

9.2. Гипотеза и условия её опровержения — 10 баллов

- **3 балла — наклон.** До просмотра результатов записано конкретное предсказание для c с объяснением его выбора. Гипотеза из предварительно сданной части 1 приведена в отчёте и не заменена задним числом на результат подгонки.
- **3 балла — дистракторы и паддинг.** Заранее указаны ожидаемый сдвиг M^* при добавлении D дистракторов и ожидаемый эффект добавления P паддинг-токенов. Эти два изменения различены и связаны с подсчётом записей.
- **2 балла — проверяемость.** Для предсказания о c и для предсказаний о сдвигах названо конкретное измерение, которое их опровергло бы: что сравнивается и какой исход противоречит гипотезе. Формулировки «проверить экспериментом» недостаточно.
- **2 балла — итог проверки.** В разделе «Что изменило бы вывод» указано, какие из этих измерений сделаны, что они показали и что осталось непроверенным. Подтверждение, опровержение и недостаточность данных различены; отсутствие проверки не выдано за подтверждение.

9.3. Дизайн эксперимента — 15 баллов

- **3 балла — конфигурация.** Указаны назначенное правило, оба собственных seed, исследуемые d_k и M . Описано, что меняется и что фиксировано, включая длину последовательности, d_v и настройки обучения. Эксперимент соответствует сетке студента, а M^* определяется по отложенной точности с порогом 0.50.
- **4 балла — softmax-контроль.** Приведены результаты gate при $M = 8$ и $M = 32$, позволяющие проверить порог выше 0.95 в обеих точках. Точность softmax-контроля из сетки показана на рисунке части 2; объяснено, зачем контроль нужен для интерпретации падения точности линейной ветви.
- **4 балла — чтение кривых.** Обучающая и отложенная точность показаны вместе и сопоставлены. По их поведению обсуждается, измеряется ли предел состояния или запоминание обучающей выборки весами. Точки с non_monotone, если они есть, разобраны отдельно и не объявлены доказательством предела памяти; если их нет, это указано.
- **4 балла — сравнение с эталоном.** Собственные результаты сопоставлены с эталоном для того же правила с учётом seed и разброса. По эталону обеих ветвей проверено предсказание о delta и linear. Выводы опираются на конкретные точки или кривые; возможное расхождение обсуждается через допущения теории и поведение модели.

9.4. Аппроксимация — 15 баллов

- **4 балла — метод подгонки.** Для собственных данных и эталона каждой ветви выполнен МНК для $M^* = c d_k + b$ со свободным членом. Описано, какие точки использованы; метод и приведённые коэффициенты соответствуют показанным прямым.

- **4 балла — seed и разброс.** c и b приведены отдельно по каждому seed. Разброс между seed указан численно и пояснён способ его вычисления, например размах или стандартное отклонение. Одно среднее без отдельных оценок и разброса не выполняет этот пункт.
- **3 балла — цензурирование.** Цензурированные точки исключены из МНК и перечислены с указанием ветви, d_k , seed и направления цензурирования. Граничное значение не выдано за измеренное M^* . Если после исключения остаётся меньше двух различных d_k , прямо указано, что наклон и свободный член по таким данным определить нельзя; отсутствие цензурированных точек также отмечено.
- **2 балла — рисунок аппроксимации.** На collapse-vs-dk.png добавлены прямые подгонки, прямая теории из части 1 и эталонные точки обеих ветвей. Добавленные линии и серии обозначены так, чтобы их можно было различить и сопоставить с текстом отчёта.
- **2 балла — интерпретация коэффициентов.** c сопоставлен с заранее записанным предсказанием, а $b - c - (D + 7)/2$. Объяснено, почему подгонка через начало координат исказила бы наклон и как это проявилось бы на рисунке.

9.5. Одно расширение — 10 баллов

Оценивается одно выбранное расширение из §6; максимум за этот критерий одинаков для всех четырёх вариантов.

- **2 балла — вопрос и предсказание.** Указано, какое расширение выбрано, какое утверждение оно проверяет и какой результат ожидается.
- **3 балла — проведение.** Выполнены предусмотренные выбранным вариантом запуски. Приведены сравниваемые конфигурации, фиксированные параметры и результаты, по которым можно провести сравнение.
- **3 балла — количественный результат.** Эффект выражен числом или показан на рисунке и сопоставлен с предсказанием. Учтены границы поиска M^* и цензурирование, если они мешают определить эффект точно.
- **2 балла — вывод.** Объяснено, что результат говорит о проверяемом утверждении и какие ограничения есть у этого вывода. Несовпадение с предсказанием само по себе не снижает балл.

Для полного балла должны быть разобраны следующие особенности выбранного варианта:

- **(a)** Сообщены результаты и по размеру чанка, и по паддингу; оценены сверху отличия, связанные с порядком суммирования. Объяснено, что означал бы провал только одного из двух контролей.
- **(b)** Измеренный сдвиг сопоставлен с $-D/2$, а также с альтернативами 0 и $-D$. Указано, какую из трактовок подсчёта записей поддерживают данные.
- **(c)** Сопоставлены ёмкости двух конфигураций с одинаковым числом элементов состояния. Объяснено, согласуется ли результат с зависимостью ёмкости от d_k при равных байтах.
- **(d)** M^* гибрида сопоставлено с соответствующей точкой без гибрида. Обсуждается вклад softmax-слоя в результат; два числа состояния для каждого слоя оцениваются в п. 9.6.

9.6. Два числа состояния — 10 баллов

- **2 балла — формулы и единицы.** Различены байты состояния на слой при заданном N и прирост байтов на токен, на слой. Используются формулы из §7 с учётом fp32 и числа голов.
- **3 балла — собственная конфигурация.** Указаны используемые H , d_k , d_v и $N = 128$; для собственной линейной ветви вычислены оба числа с единицами измерения. При выборе гибрида числа также приведены отдельно для каждого его слоя.
- **3 балла — softmax-контроль.** Для контроля при $d_k = 16$, $d_v = 64$ и $N = 128$ вычислены оба числа с единицами измерения. Расчёт относится к одному слою, а не незаметно ко всей модели.
- **2 балла — смысл сравнения.** Объяснено, какая величина зависит от N и почему одинаковые байты состояния не гарантируют одинаковую ёмкость. Не используется запрещённая формулировка «байты состояния на токен»; деление размера линейного состояния на N не подменяет прирост.

9.7. Три формы — 10 баллов

- **2 балла — перенос состояния.** Объяснено, какое состояние передаётся между чанками и как оно учитывается при чтении внутри следующего чанка.
- **3 балла — маска.** Объяснены каузальность внутричанковой маски и включение диагонали через порядок обновления состояния и чтения. Утверждение «маска треугольная» без объяснения диагонали недостаточно.
- **3 балла — арифметическая интенсивность.** Разница в скорости рекуррентной и параллельной форм объяснена через отношение вычислений к переносу данных и использование вычислительных ресурсов. Меньшее число FLOP не отождествлено с меньшим временем работы.
- **2 балла — последовательные шаги.** Показано, как зависимость по времени ограничивает параллелизм рекуррентной формы и чем в этом отношении отличаются параллельная и чанковая формы.

9.8. Оформление отчёта — 10 баллов

- **2 балла — объём и структура.** Соблюдены 3–4 страницы и порядок разделов из §8; все обязательные разделы присутствуют.
- **2 балла — подписи к рисункам.** Подпись к каждому рисунку формулирует конкретное утверждение, которое он подтверждает или проверяет, а не только повторяет название графика.
- **1 балл — размещение рисунков.** Рисунки в отчёте показаны в достаточном масштабе для чтения; при вставке не обрезаны кривые и надписи. Оформление осей, единиц и базовых легенд, создаваемых plot, отдельно не оценивается.
- **2 балла — согласованность чисел.** Числа, коэффициенты и обозначения в тексте совпадают с рисунками и таблицами. Для приводимых значений понятно, к какой конфигурации они относятся.
- **3 балла — обоснованность изложения.** Существенные утверждения связаны с конкретным рисунком, числом или расчётом. Наблюдения отделены от предположений; итоговый вывод отражает данные и ограничения проведённой проверки.

9.9. Типичные ошибки

Это не отдельные штрафы, а пояснения к пунктам выше:

- Подсчёт W по парам вместо токенов снижает балл за число записей в п. 9.1. Последствия этой ошибки для дальнейшего вывода оцениваются по правилу об одной перенесённой ошибке.
- Подгонка без свободного члена не выполняет требование к методу в п. 9.4; включение цензурированных точек — требование к обработке цензурирования в том же пункте.
- Усреднение по seed без отдельных коэффициентов и разброса не выполняет соответствующий пункт 9.4.
- Только отложенная точность без обучающей не позволяет получить полный балл за чтение кривых в п. 9.3.
- Два числа состояния только для одной ветви оставляют незачтённым расчёт для второй ветви в п. 9.6. Формулировка «байты состояния на токен» снижает балл за смысл сравнения в том же пункте.
- Утверждение без рисунка, числа или расчёта не получает полный балл за обоснованность изложения в п. 9.8.